

Liste des Ressources et Matériels Requis - Projet Simulation Vocale BMCI

Cette liste synthétique regroupe les demandes concrètes pour le déploiement et l'industrialisation du projet (exécutions locales, APIs et hébergement Moshi).

1. Ressources Matérielles (Hardware)

- Pour le développement local et le Fine-Tuning de petits modèles (SLM) :
 - 1 Station de travail équipée d'une carte graphique **NVIDIA RTX 4080 ou 4090 (minimum 16 à 24 Go de VRAM dédiée)**. *Indispensable pour faire tourner CUDA, PyTorch et entraîner les modèles locaux.*
 - Pour l'hébergement du modèle Speech-to-Speech (Moshi) :
 - 1 Instance de serveur Cloud Linux (Ubuntu) dotée d'une carte **NVIDIA L4, A10G, ou A100 (minimum 16 à 24 Go de VRAM)**. *Moshi ne peut pas fonctionner en temps réel sans un GPU professionnel.*
-

2. Comptes & Clés d'APIs (Accès Cloud)

- Cerveau (LLM) :
 - Accès à une **API payante** (au choix : *Mistral API, OpenAI API, Gemini API*) avec quotas de production, **OU** accès aux serveurs d'inférence LLM internes existants de la BMCI.
 - Écoute (STT) :
 - Clé d'API payante pour la transcription en temps réel (*Cohere Transcribe v2* ou *Whisper API*).
 - Voix (TTS) :
 - Clé d'API payante pour la synthèse vocale émotionnelle (*Mistral Voxtral* pour la voix en colère de Marie, ou *Hume AI / ElevenLabs*).
-

3. Infrastructure & Téléphonie

- Hébergement WebRTC :
 - Un abonnement **LiveKit Cloud** de production **OU** l'allocation d'une Machine Virtuelle (VM Linux) dédiée à la BMCI pour y déployer un serveur LiveKit open-source auto-hébergé.
- Interfaçage Téléphonique (SIP / VoIP) :

- Un abonnement à un **Trunk SIP** (ex: Twilio, Telnyx) pour relier les appels téléphoniques des stagiaires à l'agent vocal.
-

□ 5. Spécificités d'Intégration pour MOSHI (Kyutai)

Si le modèle Speech-to-Speech natif **Moshi** est retenu :

1. **GPU Serveur obligatoire** (aucune inférence CPU temps réel possible).
2. **Environnement Linux (Ubuntu)** obligatoire en production.
3. **Temps de développement requis** pour :
 - L'intégration du codec audio Mimi côté client.
 - Le codage d'un système de détection d'activité vocale (VAD) pour gérer l'interruption de l'IA (Barge-in).
 - L'analyse du monologue textuel de Moshi en arrière-plan pour déclencher les appels d'API bancaires (Function Calling).