

🎤 Présentation d'Avancement : Agent Vocal Interactif (LiveKit)

✈ Diapositive 1 : Page de Garde

Simulation d'un Client Bancaire par Agent Vocal Interactif

Bilan des Travaux, Expérimentations et Perspectives d'Évolution

- **Contexte** : Stage de Recherche & Développement - Atlas Bank
 - **Objectif** : Créer un agent de simulation de négociation commerciale réaliste.
 - **Technologie principale** : LiveKit WebRTC, APIs Cloud & Modèles Locaux.
-

✈ Diapositive 2 : Le Cas d'Usage de la Simulation

Scénario "M. Orens" (Le Client Mécontent)

- **Le Rôle de l'IA** : Incarner M. Orens, un client pressé et énervé qui exige de retirer immédiatement **100 000 dirhams en espèces** pour finaliser l'achat d'une maison.
 - **Le Défi pour le Conseiller (l'apprenant)** : Faire face à la colère, proposer des alternatives (comme le virement rapide) tout en respectant la limite de sécurité réglementaire de **50 000 dirhams par jour**.
 - **Contraintes Techniques** :
 - Voix expriment la colère et la frustration.
 - Latence inférieure à 1,5 seconde.
 - Possibilité de couper la parole de l'agent (Full-Duplex / Barge-in).
-

✈ Diapositive 3 : Chronologie du Projet (Début → Aujourd'hui)

Les Grandes Étapes du Travail Pratique

1. Étape 1 : État de l'Art & Benchmarks

- Recherche théorique et développement de scripts pour comparer les meilleurs modèles de voix (TTS) et d'écoute (STT) du marché.

2. Étape 2 : Prototypage Vocal (LiveKit)

- Développement de l'architecture d'agent vocal en temps réel via WebRTC.

3. Étape 3 : Résilience & Optimisation

- Résolution des crashes, création du superviseur automatique, nettoyage textuel et

✈ Diapositive 4 : État de l'Art - Sélection des Modèles

La confrontation Local (PC) vs. APIs (Cloud)

- **Le Local** : Testé pour des raisons de gratuité et de confidentialité.
 - *Constat* : Inenvisageable sur la machine de développement (CPU standard portable). L'entraînement de modèles de voix (F5-TTS) est impossible par manque de VRAM, et l'inférence prend plus de 2 minutes pour 3 secondes de voix.
 - **Le Cloud (APIs)** : Choisi comme solution pivot pour déporter la puissance de calcul.
 - *Constat* : Temps de réponse ultra-rapides ($< 1,5s$) et modèles d'intonation de qualité supérieure.
-

✈ Diapositive 5 : Résultats des Tests TTS (Synthèse Vocale)

Échecs, Réussites et Choix Finaux

- **Hume AI (Benjamin)** :
 - *Résultat* : **Réussite Qualitative / Échec Technique**. Voix incroyablement naturelle (MOS de 4.03), mais bloquée par des quotas d'essai stricts (erreurs HTTP 429).
 - **F5-TTS (Local)** :
 - *Résultat* : **Échec Temps Réel**. Excellente voix, mais génère en 128 secondes pour 3 secondes de voix (RTF de 37.4).
 - **ElevenLabs (Adam)** :
 - *Résultat* : **Réussite Modérée**. Permet de générer des rires ou soupirs, mais s'avère coûteux et présente une latence réseau sensible.
 - **Mistral Voxtral (Marie angry)** :
 - *Résultat* : **Grande Réussite (Choix Actuel)**. Voix nativement en colère, très stable, temps de réponse court (1.57s) et quotas fiables.
-

✈ Diapositive 6 : Résultats des Tests STT (Reconnaissance Vocale)

Échecs, Réussites et Choix Finaux

- **ElevenLabs Scribe v2** :

- **Résultat : Échec Temps Réel.** Excellente précision (3.12% de WER), mais latence de 21 secondes.
 - **Whisper Large-Turbo (Local) :**
 - **Résultat : Échec CPU.** Plus de 2 minutes de calcul pour transcrire 3 minutes de voix.
 - **Cohere Transcribe v2 :**
 - **Résultat : Grande Réussite (Choix Actuel).** Transcription très précise (5.82% de WER), robuste aux bruits d'agence, et quasi-instantanée en streaming.
-

✈ Diapositive 7 : L'Option LiveKit & Ses Avantages

Pourquoi avoir choisi LiveKit pour le temps réel ?

- **Le Full-Duplex :** L'utilisateur et le robot peuvent se parler en continu sans appuyer sur aucun bouton (comme lors d'un vrai appel téléphonique).
 - **Le Barge-in automatique :** Dès que l'utilisateur commence à parler, l'agent interrompt sa phrase à la milliseconde près pour l'écouter.
 - **Modularité totale :** Possibilité de changer de modèle (STT, LLM, TTS) en modifiant seulement quelques lignes de code grâce à des plugins standardisés.
 - **Hébergement cloud gratuit :** Infrastructure WebRTC gérée sur LiveKit Cloud pour les tests.
-

✈ Diapositive 8 : Résultats Obtenus sur LiveKit

Les Fonctionnalités Pratiques Implémentées

- **Le Superviseur de Résilience (`run_agent.py`) :** Détection des déconnexions du playground et redémarrage automatique de l'agent en moins de 2 secondes.
 - **Optimisation des Tours de Parole (`min_delay=0.8`) :** Une pause fixe de 0,8s de silence configurée pour s'assurer que l'écoute (STT) reçoive la phrase en entier avant que le LLM ne réponde.
 - **Filtre anti-didacalies et anti-épellation :** Nettoyage automatique des crochets émotionnels (`[gasp]`) et conversion des mots en majuscules (MON → mon) pour éviter que la voix ne les épelle lettre par lettre.
-

✈ Diapositive 9 : Limites Rencontrées dans tout le Projet

Les Goulots d'Étranglement Techniques

1. **Contrainte Matérielle Locale :** CPU insuffisant pour faire tourner le STT, le VAD et le TTS en local sans latence critique.
2. **Latence cumulée en cascade :** L'enchaînement STT (Cohere) → LLM (Mistral) → TTS (Voxtral) induit un délai de 1 à 1,5s dû aux requêtes réseau successives.
3. **Absence de streaming sur Mistral TTS :** L'agent doit attendre la génération de la

phrase complète pour la lire, créant un léger temps mort.

4. **Quotas d'APIs gratuits** : Blocages fréquents (erreurs HTTP 429) sur Hume AI et Gemini API lors des phases de tests rapides.
-

✈ Diapositive 10 : Perspectives d'Évolution

Pistes pour amener le projet en production

- **Piste 1 : Passage au Speech-to-Speech (S2S) natif :**
 - Intégrer les APIs *OpenAI Realtime* ou *Gemini Multimodal Live* pour éliminer la cascade (STT/LLM/TTS) et descendre sous les **400ms de latence globale** (conversation instantanée).
- **Piste 2 : Déploiement Local sur Serveur GPU Dédié :**
 - Héberger des modèles open-source (*Whisper-Faster* local et *Llama 3*) sur un serveur cloud GPU pour éliminer les abonnements payants tout en gardant une vitesse maximale.
- **Piste 3 : Passage aux comptes APIs payants :**
 - Lever les limites 429 en acquérant un plan professionnel Hume AI/ElevenLabs.