

Rapport Technique : Spécifications de Fine-Tuning & Analyse des Modèles Étudiés

Ce rapport a pour but de guider les équipes techniques d'**Atlas Bank** sur les prérequis nécessaires pour le fine-tuning (ajustement) des modèles de voix, de transcription et de langage, ainsi que de récapituler les caractéristiques des modèles étudiés lors de notre benchmark.

I. Spécifications pour le Fine-Tuning par Type de Modèle

1. Synthèse Vocale (TTS - Text-to-Speech)

Le fine-tuning en synthèse vocale sert à cloner une voix spécifique pour lui faire lire n'importe quel texte avec les émotions voulues (colère, calme).

- **Volume de données requis :**
 - **Clonage basique (Few-Shot) :** 1 à 3 minutes d'audio de haute qualité suffisent.
 - **Fine-Tuning professionnel (Modèle dédié) :** 30 minutes à 2 heures d'audio de haute qualité.
 - **Format des données :**
 - Fichiers audio au format **WAV**, échantillonnés à **22050 Hz** ou **44100 Hz**, en **Mono** (1 seul canal).
 - Audio nettoyé (pas de bruit de fond, pas de musique, pas d'échos).
 - Découpage en courts extraits (de 2 à 10 secondes par fichier).
 - Un fichier texte de métadonnées (généralement `metadata.csv`) associant le nom de chaque fichier audio à sa transcription écrite exacte (ex: `audio_01.wav` | `Bonjour, je voudrais faire un retrait.`).
 - **Matériel de calcul (GPU) :**
 - Inenvisageable sur CPU. Requiert un GPU Nvidia avec au moins **16 Go à 24 Go de VRAM** (ex : Nvidia RTX 3090, RTX 4090, ou GPU cloud A10G/A100).
 - **Temps d'entraînement :**
 - Environ **2 à 6 heures** sur un GPU professionnel.
-

2. Reconnaissance Vocale (STT - Speech-to-Text)

Le fine-tuning en reconnaissance vocale sert à apprendre au modèle à mieux transcrire des accents spécifiques, des termes techniques bancaires ou des noms propres propres à Atlas Bank.

- **Volume de données requis :**
 - **Ajustement léger (Vocabulaire) :** Aucun entraînement (on utilise la technique

- de "prompting" ou "hotwords" en passant une liste de mots-clés par API).
- **Fine-Tuning profond (Whisper) : 10 à 50 heures** d'enregistrements audio variés.

- **Format des données :**

- Fichiers audio (WAV or MP3) de conversations réelles enregistrées dans des conditions d'utilisation réelles (bruit d'agence, appels téléphoniques).
- Fichiers de transcription au format texte avec horodatage (couplage précis de l'audio et du texte).

- **Matériel de calcul (GPU) :**

- Requiert une puissance importante : GPU avec au moins **24 Go de VRAM** (RTX 4090 ou A100).

- **Temps d'entraînement :**

- De **12 heures à 3 jours** selon le volume du dataset.
-

3. Modèle de Langage (LLM)

Le fine-tuning du LLM sert à lui enseigner le scénario de négociation bancaire exact, la politique interne d'Atlas Bank, et le comportement psychologique de M. Orens.

- **Volume de données requis :**

- **Fine-tuning par LoRA (méthode légère recommandée) : 500 à 2 000** exemples de dialogue.

- **Format des données :**

- Fichier structuré en **JSON Lines (JSONL)** au format Chat (Système, Utilisateur, Assistant).
- Exemple de structure de données :

```
{"messages": [{"role": "system", "content": "Tu es M. Orens..."}
```

- **Matériel de calcul (GPU) :**

- Un GPU grand public comme la **RTX 3090 / 4090 (24 Go de VRAM)** est largement suffisant grâce aux techniques d'optimisation (QLoRA).

- **Temps d'entraînement :**

- **1 à 3 heures** pour un modèle de 7 ou 8 milliards de paramètres (type Llama 3 ou Mistral 7B).
-

II. Analyse Comparative des Modèles Étudiés (Benchmarks)

Voici la fiche technique des modèles que nous avons testés et comparés durant le projet.

🔊 1. Modèles de Synthèse Vocale (TTS)

A. Les Modèles Cloud (API)

- **Hume AI (Voix : Benjamin) :**

- *Caractéristiques* : Modèle empathique générant des émotions naturelles basées sur une description textuelle.
- *MOS (Qualité)* : **4.03 / 5** (Le plus naturel).
- *Latence* : 1.97 s.
- *Forces* : Qualité vocale impressionnante, gestion fine du ton de la voix.
- *Faiblesses* : Latence élevée et quotas gratuits très stricts (erreur 429 fréquente).

- **Mistral Voxtral (Voix : Marie angry) :**

- *Caractéristiques* : Modèle de synthèse de Mistral AI.
- *MOS (Qualité)* : **3.78 / 5**.
- *Latence* : **1.57 s** (Rapide).
- *Forces* : Voix en colère native extrêmement convaincante, très grande stabilité des quotas de l'API.
- *Faiblesses* : Ne supporte pas le streaming de tokens (l'agent doit attendre la fin de la phrase avant de parler).

- **ElevenLabs (Voix : Adam / Eleven v3) :**

- *Caractéristiques* : Leader du clonage de voix.
- *MOS (Qualité)* : **3.45 / 5**.
- *Latence* : 1.96 s.
- *Forces* : Capable de générer des rires, soupirs et chuchotements à partir de tags textuels [sighs].
- *Faiblesses* : Assez lent pour le temps réel et coûteux en production.

- **Google TTS & Edge-TTS :**

- *MOS (Qualité)* : ~3.55 / 5.
- *Latence* : **0.46 s à 0.70 s** (Ultra-rapides).
- *Forces* : Extrêmement rapides et très économiques.
- *Faiblesses* : Voix trop neutres, lisses et robotiques, inadaptées pour simuler la colère.

B. Les Modèles Locaux

- **F5-TTS :**

- *Caractéristiques* : Modèle open-source de clonage de voix non-autorégulatif.
- *MOS (Qualité)* : **3.79 / 5** (Excellent naturel).
- *Latence* : **127.91 s** (Sur CPU).
- *Forces* : Clone une voix avec seulement 3 secondes de référence. Gratuit et open-source.
- *Faiblesses* : **Inutilisable** en direct sans un GPU puissant dédié.

- **MeloTTS & Kokoro v0.19 :**

- *MOS (Qualité)* : 3.17 à 3.56 / 5.

- *Latence* : 3.03 s à 7.98 s.
 - *Forces* : Légers et faciles à déployer.
 - *Faiblesses* : Manque d'expressivité et voix françaises moyennes.
-

🔊 2. Modèles de Reconnaissance Vocale (STT)

- **Cohere Transcribe v2 :**

- *WER (Taux d'erreur)* : **5.82%** (Très précis).
- *Latence* : **5.43 s** (Pour l'analyse de gros fichiers) / Temps réel instantané.
- *Forces* : Gère extrêmement bien le bruit de fond et les accents. Très rapide en streaming.
- *Faiblesses* : Nécessite une connexion Internet stable.

- **ElevenLabs Scribe v2 :**

- *WER (Taux d'erreur)* : **3.12%** (La meilleure précision).
- *Latence* : **21.02 s** (Trop lent pour le direct).
- *Forces* : Qualité de transcription quasi-parfaite sur les termes financiers.
- *Faiblesses* : Latence inutilisable pour un agent de discussion en direct.

- **Whisper Large-Turbo (Local) :**

- *WER (Taux d'erreur)* : **6.03%**.
 - *Latence* : **132.91 s** (Sur CPU).
 - *Forces* : Open-source, gratuit, fonctionne hors-ligne.
 - *Faiblesses* : Trop lourd en calcul sur un ordinateur portable d'internat.
-

📄 3. Modèles de Langage (LLM - Le Cerveau)

- **Google Gemini 2.5 Flash :**

- *Type* : Modèle cloud multimodal.
- *Forces* : Extrêmement rapide pour générer les premiers jetons (TTFT très bas), gratuit.
- *Faiblesses* : Limites de requêtes gratuites trop basses pour des tests en continu (erreur 429 fréquente).

- **Mistral Small (mistral-small-latest) :**

- *Type* : Modèle cloud via API OpenAI.
- *Forces* : Excellente maîtrise du français et du contexte de négociation. Pas de blocage de quota.
- *Faiblesses* : Légèrement plus lent que Gemini au démarrage de la réponse.